

# Modeling Crisis Dynamics with Volatility-Modulated Neural SDEs

Distinguishing Panic from Trends in COVID-19 Information Diffusion

Zirui CHEN

2026 年 2 月 2 日

## 摘要

重大公共卫生危机（如 COVID-19）期间的社交媒体信息传播具有显著的“双重性”：既包含由事实驱动的确定性趋势，也包含由谣言和恐慌驱动的随机爆发。传统的神经点过程模型（Neural TPPs）通常假设事件强度仅依赖于历史状态的确定性演化，忽略了“不确定性”（Volatility）本身作为预测因子的因果力量。为了填补这一空白，本研究提出了一种**语义波动率调制神经 SDE (SV-NSDE)**。该模型基于神经赫斯顿（Neural Heston）架构，将潜在状态解耦为“语义趋势”与“随机波动率”两个耦合过程，并通过双通道门控机制显式地利用波动率来驱动事件强度的预测。本研究计划在 Weibo-COV 数据集上验证该模型，旨在为危机管理提供能够区分“常规热点”与“恐慌爆发”的计算工具。

## 1 Introduction & Motivation

在重大公共卫生危机期间，社交媒体充当着社会的“数字神经系统”。对在线话语的时间动态进行建模，是实现危机预警的关键。

### 1.1 现有方法的局限性

经典的神经时序点过程（如 RMTTP, Neural Hawkes）主要依赖于“**状态依赖**”（State-Dependent）假设：即事件的到达率是由系统的**确定性趋势**驱动的（例如，一条明确的负面新闻导致了发帖量的激增）。

然而，这种范式在处理危机初期动态时往往失效，因为它忽略了“**不确定性驱动的爆发性**”（Uncertainty-Driven Burstiness）。在危机早期，网络讨论的激增往往是由信息的匮乏——相互矛盾的谣言、模糊的通报和集体焦虑——所触发的，舆论的“均值漂移”（Mean Drift）可能尚处于稳定状态，但其“扩散项”（Diffusion/Volatility）却在剧烈飙升。

## 1.2 核心洞察：波动率作为预测因子

现有的神经 SDE 研究 (jia2019neural; zhang2024neural) 虽然引入了随机扩散项，但通常将扩散视为被动噪声。我们认为，在危机动力学中，**波动率 (Volatility) 不应被视为背景噪声，而是一个能够预示结构性突变的主动信号**。高强度的“语义熵”往往是流量爆发的前兆。

因此，本研究提出 SV-NSDE 模型，通过引入波动率耦合强度函数，强制模型学习“局势困惑度” (Volatility) 与“公众反应速度” (Burstiness) 之间的因果联系。

## 2 Preliminary Data Analysis

为了验证上述动机，我们对 Weibo-COV 数据集进行了初步的探索性分析。

### 2.1 数据来源

本研究使用 Weibo-COV 数据集，重点关注 2020 年 1 月（疫情爆发期）至 12 月（常态化防控期）的微博文本流。预处理后的事件数据包含发帖时间、文本内容（用于提取语义向量  $\mathbf{x}$ ）及级联结构。

### 2.2 长尾分布与爆发性

如图 1 所示，级联规模呈现显著的幂律分布 (Power-law)。绝大多数级联规模极小，但存在极少数  $10^6$  量级的“病毒式传播”。这种极度不均匀的分布暗示了背后的驱动机制并非单一的线性增长，而是包含某种“自激”或“突变”机制。

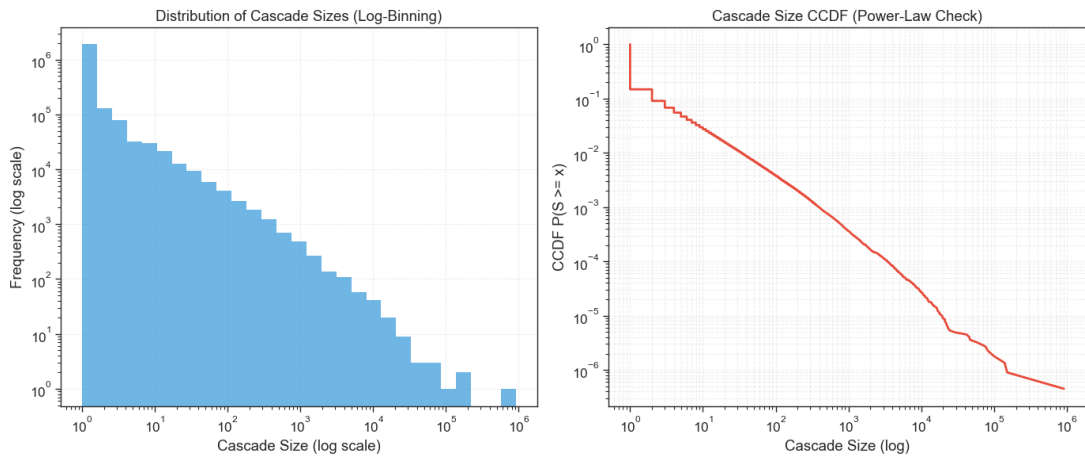


图 1: 级联规模分布 (左) 与 CCDF (右)，显示出明显的长尾特征。

## 2.3 非线性生长轨迹

分析大级联的生长轨迹（图 2）可以发现，许多级联并非平滑增长，而是呈现出“阶梯状”跃迁。特别是在危机初期，某些话题在沉寂（平台期）数小时后突然爆发。这支持了我们需要引入 **\*\*Jump-Diffusion\*\*** 机制来捕捉这种非连续变化的假设。

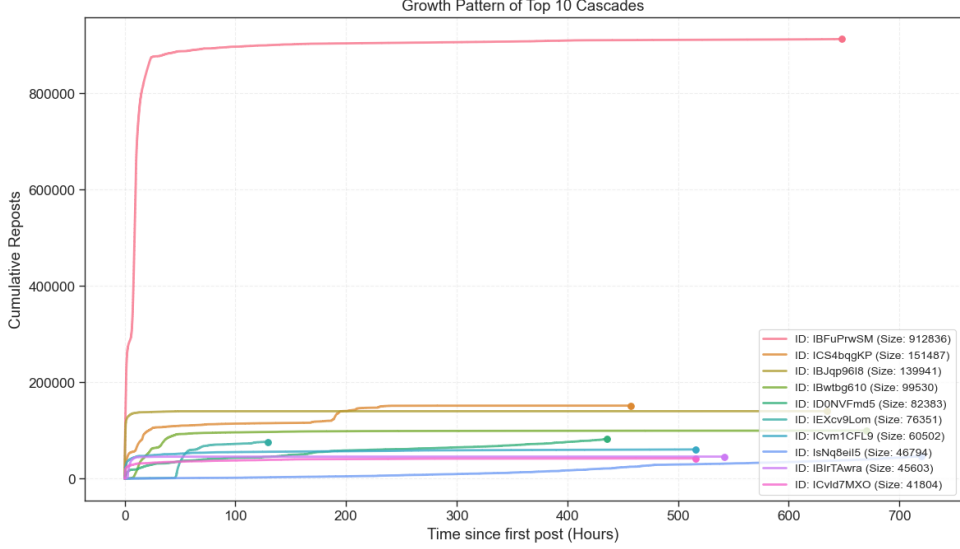


图 2: Top 10 大级联的生长轨迹，呈现出非线性的爆发特征。

## 3 Methodology

我们将社交媒体数据流建模为一个标记时序点过程  $\{(t_i, \mathbf{x}_i)\}_{i=1}^N$ ，其中  $\mathbf{x}_i \in \mathbb{R}^d$  是由 RoBERTa 提取的语义向量。

### 3.1 Semantic Encoding & Feature Extraction

在将微博文本输入 SV-NSDE 模型之前，我们需要将其映射为包含丰富语义信息的高维稠密向量。考虑到社交媒体文本通常具有短小、口语化且包含大量中文特有语义单元（如成语、专有名词）的特点，本研究采用 RoBERTa-wwm-ext (**cui2020revisiting**) 作为文本编码器。

**预训练模型选择.** 与传统的 BERT 模型不同，RoBERTa-wwm-ext 针对中文语境进行了全词掩码（Whole Word Masking, WWM）优化。当一个汉字被掩码（Mask）时，该策略会强迫模型预测属于同一个词的其他汉字，从而学习到更完整的语义单元表示。这对于捕捉疫情期间的特定术语（如“气溶胶”、“方舱医院”）以及公众情绪的细微差别至关重要。

**编码过程.** 对于第  $i$  个事件  $(t_i, \mathcal{T}_i)$ , 其中  $\mathcal{T}_i$  是原始微博文本序列。我们首先将其截断或填充至固定长度  $L$  (例如  $L = 128$ ), 并添加特殊标记 ‘[CLS]’ 和 ‘[SEP]’。

$$\mathbf{H}_i = \text{RoBERTa}(\text{Tokenizer}(\mathcal{T}_i)) \in \mathbb{R}^{L \times D_{bert}} \quad (1)$$

其中  $D_{bert} = 768$  是 RoBERTa 隐藏层的维度。我们提取 ‘[CLS]’ 标记对应的输出向量  $\mathbf{h}_i^{[CLS]}$  作为整条微博的句向量表示。

**语义投影 (Semantic Projection).** 由于  $D_{bert} = 768$  的维度远高于 SDE 潜在状态  $\mathbf{z}(t)$  的维度 (通常设定为 16-64 维), 直接将高维稀疏向量输入 SDE 可能会导致 “维度灾难” 并增加计算噪声。因此, 我们引入一个可训练的线性投影层 (Linear Projection Layer) 将语义向量压缩至输入空间维度  $d_{in}$ :

$$\mathbf{x}_i = \mathbf{W}_p \mathbf{h}_i^{[CLS]} + \mathbf{b}_p, \quad \mathbf{x}_i \in \mathbb{R}^{d_{in}} \quad (2)$$

最终得到的  $\mathbf{x}_i$  即为方程 (3) 中跳跃项  $\mathbf{J}_\phi(\mathbf{z}(t^-), \mathbf{x}_i)$  的外部输入。它代表了该条微博携带的 “信息量”, 将作为随机冲击 (Stochastic Shock) 瞬间改变舆论的潜在轨迹。

### 3.2 模型概览: Neural Heston SDE

受金融数学中 Heston 模型的启发, 我们将舆论的潜在状态建模为一个耦合随机微分方程组。该系统解耦了 “语义趋势” 与 “随机波动率”。

### 3.3 耦合 SDE 动力学

我们在连续时间段内定义潜在状态的演化:

$$\begin{cases} d\mathbf{z}(t) = \underbrace{\boldsymbol{\mu}_\theta(\mathbf{z}(t), t)dt}_{\text{Flow}} + \underbrace{\sqrt{\mathbf{v}(t)} \odot d\mathbf{W}_z(t)}_{\text{Stochastic Volatility}} + \underbrace{\mathbf{J}_\phi(\mathbf{z}(t^-), \mathbf{x}_i)dN(t)}_{\text{Event Jump}} \\ d\mathbf{v}(t) = \underbrace{\boldsymbol{\kappa}(\boldsymbol{\theta} - \mathbf{v}(t))dt}_{\text{Mean Reversion}} + \underbrace{\boldsymbol{\xi}\sqrt{\mathbf{v}(t)} \odot d\mathbf{W}_v(t)}_{\text{Vol of Vol}} \end{cases} \quad (3)$$

其中:

- $\mathbf{z}(t)$  代表舆论的主流语义轨迹。
- $\mathbf{v}(t)$  是瞬时方差过程, 服从 CIR (Cox-Ingersoll-Ross) 过程。它保证了波动率始终为正, 并具有均值回归特性 (即恐慌最终会冷却)。
- $\mathbf{J}_\phi$  是跳跃网络, 当新事件  $(t_i, \mathbf{x}_i)$  发生时, 根据当前状态和输入文本内容, 对潜在状态进行瞬时更新。

### 3.4 波动率耦合强度函数 (Dual-Channel Intensity)

我们设计了一个双通道门控机制，显式区分趋势驱动与波动率驱动：

$$\lambda(t) = \text{Softplus} \left( \underbrace{\mathbf{w}_{tr}^\top \mathbf{m}(\mathbf{z}(t))}_{\text{Channel 1: Trend Driver}} + \underbrace{\mathbf{w}_{vol}^\top \mathbf{g}(\mathbf{v}(t))}_{\text{Channel 2: Volatility Driver}} + \mu_{base} \right) \quad (4)$$

- **Channel 1 (Trend):** 捕捉常规热点（如确诊数据发布），强度随语义状态  $\mathbf{z}(t)$  变化。
- **Channel 2 (Volatility):** 捕捉恐慌性爆发。即使  $\mathbf{z}(t)$  保持稳定，只要不确定性  $\mathbf{v}(t)$  激增，该通道也会推高事件发生率  $\lambda(t)$ 。

### 3.5 Semantic Decoding (Emission Model)

为了确保潜在 SDE 轨迹  $\mathbf{z}(t)$  能够真实地反映舆论的语义演变，而不仅仅是拟合时间点，我们引入了一个生成式解码器。我们将文本语义向量的生成建模为以潜在状态为条件的高斯发射过程 (Conditional Gaussian Emission Process) \*：

$$p(\mathbf{x}|\mathbf{z}(t)) = \mathcal{N}(\mathbf{x}; \mu_{dec}(\mathbf{z}(t)), \sigma_{obs}^2 \mathbf{I}) \quad (5)$$

其中：

- $\mathbf{x} \in \mathbb{R}^{d_{in}}$  是观测到的文本语义向量（即前文 RoBERTa 提取并降维后的向量）。
- $\mu_{dec}(\cdot)$  是一个解码神经网络 (MLP)，它将当前的潜在语义状态  $\mathbf{z}(t)$  映射回观测空间。
- $\sigma_{obs}^2$  是观测噪声方差，通常作为超参数固定或通过学习获得。

这一设定将模型框架扩展为变分自编码器 (VAE) 的时序版本。在训练过程中，最大化对数似然  $\log p(\mathbf{x}_i|\mathbf{z}(t_i))$  迫使  $\mathbf{z}(t)$  必须保留足够的语义信息以重构原始输入，从而防止潜在状态发生“后崩塌” (Posterior Collapse，即状态  $\mathbf{z}$  与观测数据  $\mathbf{x}$  失去关联)。

### 3.6 学习目标

采用变分推断 (Variational Inference) 最大化证据下界 (ELBO)：

$$\mathcal{L} = \underbrace{\sum_i \log \lambda(t_i) - \int_0^T \lambda(t) dt}_{\text{Event Log-Likelihood}} + \underbrace{\sum_i \log p(\mathbf{x}_i|\mathbf{z}(t_i))}_{\text{Semantic Reconstruction}} - \text{KL}(Q||P) \quad (6)$$

其中 KL 散度项通过 Girsanov 定理计算，用于约束后验路径接近先验 Heston 过程。

## 4 Experimental Plan

### 4.1 实验设置

- **数据集切分**: 将 Weibo-COV 划分为三个阶段: (1) 爆发期 (1 月-2 月, 高波动); (2) 平台期 (3 月); (3) 衰退期 (4 月, 低波动)。以此测试模型在不同危机阶段的适应性。
- **特征提取**: 使用 RoBERTa-wwm-ext 生成 768 维的文本向量, 并通过 PCA/Autoencoder 降维至潜在空间维度  $d_z$ 。

### 4.2 基线模型 (Baselines)

我们将对比三类模型:

1. **Neural Hawkes / RMTPP**: 确定性强度的 RNN 基准。
2. **Latent ODE**: 仅包含连续确定性演化的 Neural ODE。
3. **Neural Jump SDE (Anchor Baseline)**: Jia & Benson (2019) 的模型。它包含随机性, 但未解耦波动率与强度。

### 4.3 评价指标 (Metrics)

- **时间预测**: RMSE (Root Mean Square Error) 用于衡量预测下一次发帖时间的准确性。
- **语义预测**: Cosine Similarity / MSE 用于衡量预测下一条微博语义内容的准确性。
- **模型拟合**: Log-Likelihood (LL) on held-out test sets.

### 4.4 消融实验 (Ablation Studies)

为了验证 SV-NSDE 的核心假设, 我们将进行以下变体测试:

- **w/o Volatility Channel**: 去掉强度函数中的第二通道, 验证波动率是否真的对预测爆发有帮助。
- **Deterministic Volatility**: 将  $\mathbf{v}(t)$  替换为  $\mathbf{z}(t)$  的确定性函数, 验证随机建模 (SDE) 的必要性。

## 5 Conclusion

本研究提出了一种结合金融随机波动率模型与神经点过程的新框架。通过显式建模“舆论波动率”，我们期望解决现有模型难以捕捉危机初期“不确定性驱动爆发”的难题，为计算社会科学提供新的建模视角。